

AGROSEARCH — MOTOR DE BUSCA INTELIGENTE

Tendências em Ciências da Computação

Instituição: UNIPÊ Professor: Me. Ricardo Roberto de Lima

Equipe: Gabriel Xavier, Patrick Sardenbeg, Kevyn Cassiano

1. Objetivo

O AgroSearch foi desenvolvido como um protótipo de motor de busca textual para auxiliar técnicos de campo na localização de informações relevantes em uma base de manuais sobre agricultura sustentável, controle de pragas e irrigação. A solução recebe uma consulta, realiza o pré-processamento dos textos e retorna os documentos mais relevantes por meio de um ranqueamento.

2. Metodologia e implementação

Pré-processamento: o sistema realiza tokenização e normalização, convertendo o texto para minúsculas e removendo acentos. Em seguida, o usuário pode ativar ou desativar a remoção de stopwords e o stemming por meio de checkboxes na interface. O stemming foi implementado diretamente no código, sem uso de bibliotecas de alto nível.

Índice invertido: após o pré-processamento, é construída uma estrutura do tipo *Termo* → *[IDs dos documentos]*. O índice permite identificar quais documentos contêm cada termo e pode ser visualizado na aplicação em formato de tabela e JSON.

TF-IDF: o cálculo foi implementado manualmente. A frequência do termo (TF) é obtida pela frequência do termo dividida pelo número total de tokens do documento. O IDF utiliza uma formulação suavizada, $IDF = \log(N/(1+DF)) + 1$, e o TF-IDF é obtido pelo produto entre TF e IDF. Na busca, os termos da consulta encontrados nos documentos contribuem para o score de ranqueamento.

Interface: a aplicação foi desenvolvida em Streamlit e organizada em abas para busca, pré-processamento, índice invertido e TF-IDF. A consulta é digitada pelo usuário e os documentos são apresentados em ordem de relevância, com destaque para o primeiro resultado quando há correspondência.

3. Base de documentos e funcionalidades

Documento	Tema principal
Doc 1	Irrigação da soja durante a floração
Doc 2	Controle biológico de lagartas na soja
Doc 3	Adubação verde, nitrogênio e milho
Doc 4	Lagartas desfolhadoras em soja e algodão
Doc 5	Irrigação por gotejamento e cultivo orgânico

4. Bônus: similaridade de cosseno

Como extensão, foi implementada a similaridade de cosseno entre o vetor TF-IDF da consulta e o vetor TF-IDF de cada documento. A aplicação exibe esse valor junto ao ranking, permitindo observar a relação entre os termos da consulta e a representação vetorial dos documentos.

5. Conclusão

O AgroSearch integra as principais etapas propostas no desafio: pré-processamento textual, construção de índice invertido, cálculo de TF-IDF, ranqueamento e interface interativa. A implementação mantém os cálculos de recuperação de informação no próprio código, atendendo à restrição de não utilizar bibliotecas de alto nível para TF-IDF. A estrutura também permite alterar dinamicamente o processamento por meio das opções de stopwords e stemming.

Divisão de tarefas da equipe: preencher pelos integrantes antes da entrega.